




吉林大学数学建模竞赛



参赛编号： ____049____

题目： ____B____

2025

吉林省教育发展多模型预测与优化策略研究

2025 年 5 月 3 日

摘 要

本项目针对吉林省教育发展问题，构建多元线性回归模型预测未来三年义务教育、高中及高等教育在校生人数，结果显示各阶段人数呈递减趋势。通过岭回归分析人口因素对教育的影响，发现出生率、城镇化率等变量对义务教育及高等教育影响显著，而高中教育受数据波动限制拟合度较低。结合双指数平滑模型对教育经费进行时序预测，提出优化资源配置、加强职业教育及家校协同等策略。模型验证表明预测误差较小（ $RMSE=22.49$ 亿元， $MAPE=2.50\%$ ），具备较高可靠性。

关键词：多元线性回归；岭回归；双指数平滑模型；教育人口预测；人口-教育关系分析；吉林省教育策略

一、问题重述

1.1 问题背景

吉林省地处东北地区中部，是新中国汽车工业、电影工业的摇篮。吉林省的教育事业发展势头良好，各学龄阶段教育有很多优势突出、特色鲜明的学校，全省受教育人口比例、升学比例相对较高。可通过较为科学系统的数学方法对吉林省教育事业发展进行分析，为进一步提升教育品质和科学决策水平提供参考依据。

1.2 问题要求

问题一：以近几年的吉林省教育事业发展情况，建立数学模型，分别预测未来三年内吉林省义务教育阶段、高中教育阶段、高等教育阶段的在校生人数。

问题二：结合近年来的吉林省人口数据，分析吉林省人口与本省各阶段教育之间的影响。

问题三：为提振吉林省经济发展，希望通过加大对教育事业的投入吸引人才，减少人口外流。请结合近几年的吉林省教育经费数据，对未来三年内吉林省各项教育经费做出合理预算，为提高各阶段教育水平提出合适的策略分析。

二、符号说明

符号	说明
X_1	出生率/%
X_2	死亡率/%
X_3	人口自然增长率/%
X_4	城镇化率/%
X_5	年末常驻人口数/万人
X_6	义务教育学校数
X_7	高中教育学校数
X_8	高等教育学校数
X_9	吉林省总户数/万人
X_{10}	吉林省户均人口/（人/户）
$Y^{(1)}$	义务教育在校生人数/万人
$Y^{(2)}$	高中教育在校生人数/万人
$Y^{(3)}$	高等教育在校生人数/万人
ℓ_t	双指数平滑模型中时间点 t 的水平估计
b_t	双指数平滑模型中时间点 t 的趋势估计
H_s	双指数平滑模型中的水平平滑系数
T_s	双指数平滑模型中的趋势平滑系数
h	双指数平滑模型中的预测步长
β_n	多元线性回归系数
γ	岭回归系数向量
γ_n	岭回归系数

三、问题分析

- 针对问题一：考虑到有准确的在校生人数历史数据 [1]（整理后如下图 3-1）




图 3-1

故可以选择建立时间序列模型，因其无需对复杂的因果关系进行深入分析，且适合短期预测。但通过实际计算我们发现义务教育和高等教育的相关数据不满足时间序列的建立条件，即时间序列不平稳，且在进行一阶差分之后仍不平稳（具体见附件代码）。这意味着时间序列模型的基本假设不成立，因此无法直接应用。

为了避免这一问题，我们转而考虑多元线性回归模型预测第一题。该模型不仅能够处理多重变量之间的关系，还能够解决数据不平稳的问题，符合第一题的实际情况。并且，多元线性回归模型具有较高的解释性，能够通过回归系数反映各个自变量对因变量的具体贡献，给出更为合理的预测结果。因此，最终我们决定使用多元线性回归模型解决第一题。

- 针对问题二：考虑到有出生率死亡率等多个已知数据 [1](整理后如下表 3-1)

年份	X_1	X_2	X_3	X_4	X_5	X_9	X_{10}
2013	7.74	5.17	2.57	55.74	2668	959.7	2.78
2014	8.03	6.45	1.58	56.81	2642	960.7	2.75
2015	6.2	5.8	0.4	57.64	2613	879.6	2.97
2016	7.45	5.95	1.49	58.75	2567	907.1	2.83
2017	7.13	6.97	0.15	59.71	2526	960.5	2.63
2018	6.35	6.79	-0.44	60.85	2484	927	2.68
2019	6.39	7.55	-1.16	61.63	2448	948.7	2.58
2020	4.84	7.81	-2.97	62.64	2399	1025.4	2.34
2021	4.7	8.08	-3.38	63.36	2375	1019.5	2.33
2022	4.33	8.4	-4.07	63.73	2348	978.2	2.4
2023	3.77	9.16	-5.39	64.72	2339	995.5	2.35

表 3-1

我们开始仍然考虑用多元线性回归模型。可以通过同时分析多个自变量与各阶段教育的线性关系，直观揭示变量间的复杂关系。但通过实际计算我们发现自变量之间的相关度过高，在多元线性回归用普通最小二乘法估计的系数方差急剧增大即容易出现过度拟合。因此无法选用多元线性回归来解决。

为了避免上述问题，我们考虑用岭回归来通过增加惩罚项压缩系数大小降低模型对数据对微小波动的敏感性，减少因共线性导致的波动。同时通过牺牲少量

偏差显著降低方差提高模型的精准度。因此我们最后选择用岭回归模型来解决第二题。

我们选择总户数，户均人口，年末常驻总人口，出生率，死亡率，人口自然增长率，城镇化率为自变量。各个阶段教育分别为因变量。

先将自变量标准化即把每个自变量的均值近似变为 0，标准差近似为 1. 然后构建岭回归模型并通过交叉验证来选出最佳的正则化参数，最后来计算岭回归系数。

模型评估通过计算出决定系数 R^2 来判断拟合的程度，决定系数越接近 1 则说明拟合的越好。

- 针对问题三：考虑到有准确的每年教育事业的投入数据 [2](整理如下表 3-2)，

年份	全省教育经费投入（亿元）
2015	597.52
2016	643.98
2017	658.67
2018	686.65
2019	677.74
2020	720.48
2021	709.2
2022	748.41
2023	835.33

表 3-2

我们选择时间序列模型进行分析，通过构建带阻尼项的指数平滑模型，对 2015-2023 年教育经费数据进行时间序列分析，利用 RMSE、MAE 和 MAPE 评估模型精度（误差值均显示较高预测准确度），并采用 Q-Q 图验证残差正态性、Ljung-Box 检验确认残差无自相关性（p 值 >0.05），结合残差时序图和分布图全面诊断模型有效性，最终形成具备统计显著性的预测工具，为教育经费趋势研判、异常波动检测及未来预算规划提供数据支持。对于各阶段教育的策略分析，在第一问中，我们预测得出了未来三年各阶段在校生的数量，并结合吉林省实际现状作为参考得出规划

四、问题一模型的建立与求解

4.1 数据分析与处理

由分析，我们将建立多元线性回归方程，因此各自变量间的相关性应尽可能弱且与在校人数相关性高。故建立模型方程为：

$$Y^{(i)} = \beta_0 + \sum_{j=1}^8 \beta_j X_j$$

我们采用最小二乘法估计系数向量 β :

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

其中 $\mathbf{X}$ 为自变量 $X_i (i = 1, \dots, 8)$ 与年份 t 的设计矩阵, $\mathbf{Y}$ 为因变量向量

由此还注意到我们还需要 2025-2027 年的 $X_1, \dots, X_8$ 。观察历年相关数据 [1] (整理如图 4-1 至 4-3)




图 4-1




图 4-2




图 4-3

可以发现各变量变化趋势呈线性, 故对各变量线性拟合, 可得其预测值 $\hat{X}_{i, future}$ 的时间序列线性回归方程:

$$\hat{X}_{i, future} = \alpha_0 + \alpha_1 t + \epsilon$$

其中 α_0 为常数, α_1 为年际变化率, ϵ 为随机误差。参数估计方法目标函数为:

$$\min_{\alpha_0, \alpha_1} \sum_{i=1}^8 [X_i - (\alpha_0 + \alpha_1 t_i)]^2$$

可解得:

$$\hat{\alpha}_1 = \frac{\sum (t_i - \bar{t})(X_i - \bar{X})}{\sum (t_i - \bar{t})^2}, \hat{\alpha}_0 = \bar{X} - \hat{\alpha}_1 \bar{t}$$

这样我们就能得到变量 $X_1, \dots, X_8$ 未来三年的预测值, 结果如下:

符号	值	符号	值	符号	值
X_1	3.624	X_1	3.213909	X_1	2.803818
X_2	9.224	X_2	9.577545	X_2	9.931091
X_3	-5.600182	X_3	-6.363545	X_3	-7.126909
X_4	65.931273	X_4	66.835273	X_4	67.739273
X_5	2276.327273	X_5	2240.427273	X_5	2204.527273
X_6	6859	X_6	6527	X_6	6195
X_7	481	X_7	475	X_7	470
X_8	68	X_8	69	X_8	70

Year1

Year2

Year3




图 4-4




图 4-5




图 4-6

4.2 建模求解

由上述分析我们知道:

$$\hat{Y}^{(i)} = \hat{\beta}_0 + \sum_{j=1}^8 \hat{\beta}_j \hat{X}_j$$

我们通过以下参数来判断模型拟合程度:

- 残差是否近似正态分布, 如果近似, 则意味着模型的误差是随机的, 没有系统性的模式, 且符合经典线性回归假设。我们检验残差后, 发现我们的模型满足近似正态分布的结果 (具体见代码)

- 异方差检验。我们通过绘制“残差拟合值”散点图，发现我们的残差在拟合值的整个范围内随机分布，没有明显规律性或趋势，表明我们的模型没有明显的异方差问题，满足方差齐性的假设。（具体见代码）

借助 statsmodels.api 库的 OLS 函数，线性回归系数的计算结果如下：

符号	值	符号	值	符号	值
β_0	2707.2656	β_0	987.3537	β_0	69.1046
β_1	-997.6949	β_1	-301.3441	β_1	208.6819
β_2	1000.0800	β_2	301.4557	β_2	-209.2665
β_3	1001.7301	β_3	301.0550	β_3	-211.1939
β_4	-22.0836	β_4	-11.0388	β_4	0.3707
β_5	-0.3513	β_5	-0.1484	β_5	-0.0291
β_6	0.0055	β_6	-0.0024	β_6	-0.0043
β_7	-1.0721	β_7	-0.1035	β_7	0.2464
β_8	2.8807	β_8	2.9065	β_8	-0.4878

$Y^{(1)}$ 的方程参数

$Y^{(2)}$ 的方程参数

$Y^{(3)}$ 的方程参数

最后，我们得出对未来三年在校生人数的预测如下：

符号	值	符号	值	符号	值
$Y^{(1)}$	167.6	$Y^{(1)}$	165.02	$Y^{(1)}$	162.43
$Y^{(2)}$	54.85	$Y^{(2)}$	54.64	$Y^{(2)}$	54.43
$Y^{(3)}$	92.29	$Y^{(3)}$	94.94	$Y^{(3)}$	97.59




图 4-7

五、问题二模型的建立和求解

5.1 数据分析与处理

由问题分析可知，我们决定采用岭回归分析法解决本题。我们将建立岭回归方程、目标是通过计算岭回归系数 其各个分量的值，通过分析比较回归系数绝对值大

小来分析比较各个自变量对在校生人数的影响大小。

$$\mathbf{y} = \mathbf{X}\boldsymbol{\gamma} + \boldsymbol{\epsilon}$$

其中 $\mathbf{y}$ 是因变量在校生人数按年份排列构成的列向量, $\mathbf{X}$ 是 7 个自变量 ($X_1, \dots, X_5, X_9, X_{10}$) 按年份排列构成的矩阵, $\boldsymbol{\gamma}$ 是岭回归系数的向量, 表示每个自变量各自的权重, $\boldsymbol{\epsilon}$ 是误差项。

我们通过 RidgeCV 模块 (具体实现见代码) 选择出相对最优 alpha 值。接着, 再用选出的 alpha 值最小化带有标准化项的损失函数, 使得模型的准确性和稳定性达到最佳。损失函数为:

$$\min_{\boldsymbol{\gamma}} \left[\sum_{i=1}^3 (\mathbf{y}^{(i)} - \mathbf{X}_i \boldsymbol{\gamma})^2 + \alpha \sum_{j=1}^7 \gamma_j^2 \right]$$

其中 $\mathbf{y}^{(i)}$ 、 $\mathbf{X}_i$ 分别表示各阶段因变量向量、各阶段自变量矩阵 ($i=1,2,3$ 分别表示义务教育阶段, 高中教育阶段, 高等教育阶段)。 α 是标准化参数, 用于控制模型的复杂度, γ_j 表示对应自变量 X_j 的回归系数 ($j=1,2,\dots,5,9,10$)。

在对自变量标准化之后, 我们仍然采用最小二乘法计算回归系数:

$$\hat{\boldsymbol{\gamma}} = (\mathbf{X}^T \mathbf{X} + \alpha \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

其中:

- $\mathbf{X}^T$ 是自变量矩阵 $\mathbf{X}$ 的转置。
- $\mathbf{I}$ 是单位矩阵, 确保正则化存在, 避免过度拟合。

5.2 建模求解

由上述分析我们知道:

$$\hat{\boldsymbol{\gamma}} = (\mathbf{X}^T \mathbf{X} + \alpha \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

我们主要通过参数 R^2 来判断模型拟合程度, 本模型中 R^2 的公式如下:

$$R^2 = 1 - \frac{\sum_{i=1}^{10} (y_i - \hat{y}_i)^2}{\sum_{i=1}^{10} (y_i - \bar{y})^2}$$

其中 y_i 表示 $\mathbf{y}$ 的第 i 个分量 (如 y_1 表示 2013 年的在校生人数)

我们将通过 R^2 接近 1 的程度来评估模型优度, R^2 越接近 1 模型优度越高。

计算过程中我们发现高中教育阶段的拟合不够理想, R^2 与 1 的接近程度明显小于义务教育阶段和高等阶段分别得到的 R^2 值。再次分析数据, 我们认为原因在于高中教育阶段数据波动太小, 线性关系较弱, 特征性不强。于是我们采用网格搜索, 通过穷举所有给定超参数的组合来选择最佳的模型超参数, 通过这种遍历的方式, 我们将拟合优度大幅提升, 最终拟合优度 R^2 接近 0.8。另外我们也发现, 虽然我们的模型对高中教育阶段的拟合不够理想, 但对于义务教育和高等教育阶段的拟合非常理想, R^2 很接近 1。

线性回归系数向量 $\boldsymbol{\gamma}$ 、 R^2 以及最佳 α 值的计算结果如下表 5-1:

符号	值	符号	值	符号	值
α	0.4642	α	0.0081	α	2.47708
γ_1	0.8652	γ_1	-3.3490	γ_1	-1.8920
γ_2	-4.5962	γ_2	-1.5243	γ_2	1.5775
γ_3	2.6845	γ_3	-1.2448	γ_3	-1.8088
γ_4	-1.0113	γ_4	-13.9089	γ_4	1.1220
γ_5	0.7258	γ_5	2.6127	γ_5	-1.1494
γ_9	1.3624	γ_9	-9.8182	γ_9	0.1425
γ_{10}	-0.7611	γ_{10}	-21.3902	γ_{10}	-0.7407
R^2	0.9321	R^2	0.7812	R^2	0.9610

义务教育

高中教育

高等教育

表 5-1

为了让数据更加直观，我们将以上数据绘制成柱状统计图如下图 5-1：




图 5-1

下面我们针对计算出的线性回归系数向量，具体分析吉林省人口与本省各阶段教育的影响关系：

首先是义务教育阶段。由上面给出的条状统计图不难发现，人口出生率和死亡率以及自然增长率对义务教育阶段在校生生人数的影响比重是最大的。这符合我们的直观认知，即婴幼儿的出生数和儿童的数量直接决定了进入义务教育阶段的学生数量，较低的出生率意味着会有更少的孩子进入学校。

其次是高中教育阶段，我们可以很明显的看到，对高中教育阶段在校生生影响最大的就是城镇化率和户均人口，城镇化率的提高通常意味着更多的青少年能够进入城市接受更好的教育资源，进而增加高中阶段在校生的数量。而户均人口则反映了家庭的平均规模，在教育支出大部分由政府承包的背景下，户均人口越多，最终进入高中的学生数也更多。

最后是高等教育阶段，对高等教育阶段在校生生人数起到影响的人口因素有很多，比如人口增长率和城镇化率，随着更多人口流入城市，城市地区的教育资源会更加丰富，更多的年轻人有机会接受高等教育。城镇化进程中的经济发展与社会转型，也会使得更多家庭有能力让孩子进入大学学习。

鉴于岭回归分析法对高中教育阶段起到的作用有限，我们决定采用皮尔逊相关性分析法，两两分析人口变量和教育的相关性，同时我们绘制相关性热力图（如下图 5-2），用图形可视化表示不同变量之间相关性，这样更为直接。颜色越深代表相关性越强，颜色越浅则代表相关性较弱。这样通过两种不同分析方法的对照，检验岭回归分析法准确度是否足够高。




图 5-2

通过分析热力图，我们发现结果与岭回归分析法最后得到的分析结果较为一致，故岭回归分析法是解决本题较为理想的分析方法。

六、问题三模型的建立与求解

6.1 数据分析与处理

由分析，本小题第一问我们将用时间序列方法解答。首先进行数据准备与预处理。（如下表所示）

年份	全省教育经费投入（亿元）
2015	597.52
2016	643.98
2017	658.67
2018	686.65
2019	677.74
2020	720.48
2021	709.2
2022	748.41
2023	835.33

吉林省教育经费投入情况（2015-2023 年）

我们以年份作为时间索引，以便对数据进行排序、索引和处理。由于数据没有缺

失值，故不需要进行插值。再将教育经费作为时序预测的数据列，以求未来三年的教育经费预测值。

考虑到近九年教育经费呈现明显的上升趋势（如下图 6-1），季节性变化较小，故我们选择双指数平滑模型对数据进行快速建模和预测。



图 6-1

6.2 建模求解

我们使用双指数平滑模型将时间序列分解为两个成分：水平和趋势，并通过指数加权的方法对这两个成分进行平滑。

首先，我们给出水平更新公式、趋势更新公式及预测公式。

水平（Level）更新公式：

$$\ell_t = H_s y_t + (1 - H_s)(\ell_{t-1} + b_{t-1})$$

趋势（Trend）更新公式：

$$b_t = T_s(\ell_t - \ell_{t-1}) + (1 - T_s)b_{t-1}$$

预测公式：

$$\hat{y}_{t+m} = \ell_t + mb_t$$

其中，符号说明：

- ℓ_t 是时间点 t 的水平估计；
- b_t 是时间点 t 的趋势估计；
- y_t 是时间点 t 的实际观测值，即本题中从 2015 年开始，每一年的教育经费。
- α 是水平平滑系数，控制对当前观测值的权重；

- β 是趋势平滑系数，控制对趋势变化的敏感度；
- h 是预测步长，取 3,4,5，分别对应未来三年。

我们通过 ExponentialSmoothing 类，启用阻尼趋势，避免预测值无限增长。同时使用最小化均方误差法自动调整水平平滑系数和趋势平滑系数，最终寻找最优平滑参数如下表所示。（具体实现见代码）

参数	值
α	0.32
β	0.66

双指数平滑模型的参数值

将 α 和 β 分别代入水平（Level）更新公式和趋势（Trend）更新公式即可求出各时间点对应的水平估计和趋势估计，如下表所示。

年份	水平估计 (ℓ_t)	趋势估计 (b_t)
2015	603.798790	23.852190
2016	627.526523	23.727200
2017	651.129633	23.602865
2018	674.609204	23.479181
2019	697.964694	23.356145
2020	721.198425	23.233755
2021	744.309291	23.112005
2022	767.299571	22.990893
2023	790.171453	22.870417

水平估计 (ℓ_t) 与趋势估计 (b_t)

从表中我们可以获取 2023 年的水平估计和趋势估计，取步长为 3，4，5 即可预测未来三年的教育经费投入，如下表所示。

年份	预测教育经费 (亿元)
2026	812.92
2027	835.55
2028	858.07

未来三年教育经费预测

绘制成折线图如下图 6-2 所示：




图 6-2

6.3 模型效果检验

1. 拟合值与残差首先我们通过模型得到拟合值，然后计算残差。通过检查残差的性质评估模型的拟合效果。

年份	残差 (Residuals)
2015	-6.28
2016	16.45
2017	7.54
2018	12.04
2019	-20.23
2020	-0.72
2021	-35.11
2022	-18.89
2023	45.16

残差表

2. 计算均方根误差、平均绝对误差、平均绝对百分比误差

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}$$

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|$$

$$\text{MAPE} = \frac{1}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right| \times 100$$

最终结果（如下表所示）均很小，表明拟合和预测结果非常优秀。

指标	值
RMSE	22.49 亿元
MAE	18.05 亿元
MAPE	2.50%

模型拟合指标

3. 绘制 Q-Q 图（结果如下图 6-3 所示），数据点大致落在参考直线附近，正态性成立。




图 6-3

4. Ljung-Box 检验。通过计算不同滞后期的自相关系数，并检验其是否显著，来判断残差序列是否存在自相关。

$$Q = n(n+2) \sum_{k=1}^m \frac{r_k^2}{n-k}$$

其中， r_k 是自相关系数， n 是样本大小， m 是滞后期数， Q 统计量用于检验是否有自相关。

将我们的数据代入公式，经检验残差不显著自相关，故可以认为我们的模型已经充分拟合，且残差类似白噪声。（具体实现见代码）

6.4 策略分析

为提高各阶段教育水平，结合第一问未来三年在校生人数预测，现给出策略分析如下：

1. 优化教育资源配置。针对吉林省部分地区义务教育阶段教育资源相对匮乏的情况，应加大财政投入，提升教育基础设施建设，吸引人才援助落后地区，从而确保城乡教育均衡发展。同时，应着重提升教师队伍素质，加大纪委监委对教务人员的监察力度，严厉打击非法补课行为，从根本上确保教师师德配位、爱护学生、有班级荣誉感，并且及时清理不作为、乱作为、嫌贫爱富、唯利是图、欺压学生的领导及教师，为吸纳的新青年教师提供良好的生态环境和晋升环境，从而促进吉林省教育事业可持续发展，长期稳定发展，留住人才。

2. 考虑到吉林省高校在校生人数逐年增加的趋势，应加大财政投入，促进高校与企业的合作，推动科研成果转化落实。同时注意到中等职业教育阶段人数的稳定性，应发展与地方经济密切相关的职业教育，多向职业教育学校拨款，调整大众对职业教育的认知，加大对职业教育学校学生的监管，提高他们的平均素养。多提供就业岗位，为区域发展提供人才支持，留住人才。

3. 由于吉林省义务教育阶段在校生人数逐年减少，应加大财政投入，给青少年提供舒适的教育环境。无论是硬件设施还是软件设施，都应尽力而为、做到最好。同时多安排家访、关注学生家庭关系、亲子关系，促进家教合一，为学生提供全面的安稳的成长环境。

参考文献

- [1] 来源：2024 吉林统计年鉴. chinese. 2025. URL: <http://tjj.jl.gov.cn/tjsj/tjnj/2024/ml/indexc.htm> (visited on 05/01/2025).
- [2] 全省教育经费投入. chinese. 2025. URL: <http://was.jl.gov.cn/was5/web/search?presearchword=&channelid=217444&StringEncoding=UTF-8&searchword=%E5%85%A8%E7%9C%81%E6%95%99%E8%82%B2%E7%BB%8F%E8%B4%B9&navss=%E6%90%9C%E6%9C%AC%E7%AB%99> (visited on 05/02/2025).

附录 A 支撑材料文件列表

文件名	文件类型	简介
多元回归模型检验.py	python 代码文件	多元回归模型检验代码
多元线性回归法.py	python 代码文件	多元线性回归法算法代码
高等教育岭回归法.py	python 代码文件	岭回归法代码
高中教育岭回归法.py	python 代码文件	岭回归法代码
义务教育岭回归法.py	python 代码文件	岭回归法代码
皮尔逊相关性分析法.py	python 代码文件	皮尔逊相关性分析法算法代码
平稳性检验 (ADF 检验).py	python 代码文件	时间序列平稳性检验代码
时序分析预测.py	python 代码文件	指数平滑法算法代码
第一题整合数据.xlsx	excel 表格文件	第一题整合数据
第二题整合数据.xlsx	excel 表格文件	第二题整合数据
第三题整合数据.xlsx	excel 表格文件	第三题整合数据
在校生人数历史数据.xlsx	excel 表格文件	在校生人数历史数据

附录 B 源数据

第一题源数据 - 部分 1

年份	年末常驻总人口/万人	出生率/%	死亡率/%
2013	2668	7.74	5.17
2014	2642	8.03	6.45
2015	2613	6.2	5.8
2016	2567	7.45	5.95
2017	2526	7.13	6.97
2018	2484	6.35	6.79
2019	2448	6.39	7.55
2020	2399	4.84	7.81
2021	2375	4.7	8.08
2022	2348	4.33	8.4
2023	2339	3.77	9.16

第一题源数据 - 部分 2

年份	人口自然增长率/%	城镇化率/%	义务教育学校数
2013	2.57	55.74	10158
2014	1.58	56.81	10087
2015	0.4	57.64	9895
2016	1.49	58.75	9635
2017	0.15	59.71	9428
2018	-0.44	60.85	8713
2019	-1.16	61.63	8571
2020	-2.97	62.64	8550
2021	-3.38	63.36	8421
2022	-4.07	63.73	7606
2023	-5.39	64.72	6322

第一题源数据 - 部分 3

年份	高中教育学校数	高等教育学校数	义务教育在校生/万人
2013	545	58	200.6861
2014	539	58	189.1687
2015	528	58	187.5284
2016	518	60	186.8488
2017	518	62	184.6909
2018	508	62	186.2507
2019	506	62	184.0219
2020	501	64	180.9959
2021	504	66	175.2226
2022	503	66	170.3864
2023	478	66	168.6234

第二题源数据 - 部分 1

年份	总户数/万户	户均人口/人/户	年末常驻总人口/万人
2013	959.74	2.78	2668
2014	960.69	2.75	2642
2015	879.64	2.97	2613
2016	907.05	2.83	2567
2017	960.49	2.63	2526
2018	927.0	2.68	2484
2019	948.65	2.58	2448
2020	1025.4	2.34	2399
2021	1019.47	2.33	2375
2022	978.2	2.4	2348
2023	995.49	2.35	2339

第二题源数据 - 部分 2

年份	出生率/%	死亡率/%	人口自然增长率/%
2013	7.74	5.17	2.57
2014	8.03	6.45	1.58
2015	6.2	5.8	0.4
2016	7.45	5.95	1.49
2017	7.13	6.97	0.15
2018	6.35	6.79	-0.44
2019	6.39	7.55	-1.16
2020	4.84	7.81	-2.97
2021	4.7	8.08	-3.38
2022	4.33	8.4	-4.07
2023	3.77	9.16	-5.39

第二题源数据 - 部分 3

年份	城镇化率/%	义务教育在校生/万人
2013	55.74	200.6861
2014	56.81	189.1687
2015	57.64	187.5284
2016	58.75	186.8488
2017	59.71	184.6909
2018	60.85	186.2507
2019	61.63	184.0219
2020	62.64	180.9959
2021	63.36	175.2226
2022	63.73	170.3864
2023	64.72	168.6234

第三题源数据

年份	全省教育经费投入/亿元
2015	597.52
2016	643.98
2017	658.67
2018	686.65
2019	677.74
2020	720.48
2021	709.2
2022	748.41
2023	835.33

附录 C 所用软件

所用软件包括：Excel、PycharmCommunity、VisualStudioCode、TexStudio

附录 D 多元回归模型检验代码

```
# 模型检验

import 多元线性回归法 as main
import statsmodels.api as sm
import matplotlib.pyplot as plt

plt.rcParams['font.sans-serif'] = ['Microsoft YaHei']

# 这里以义务教育模型为例
#1. 检查残差是否近似正态分布
resid = main.model_ 义务.resid # 获取残差
sm.graphics.qqplot(resid, line='45', fit=True)
plt.title('义务教育残差 Q-Q 图')
plt.show()
# 结果表示残差近似正态

#2. 检查是否存在异方差
fitted = main.model_ 义务.fittedvalues
plt.scatter(fitted, resid)
plt.axhline(0, color='grey', linestyle='--')
plt.xlabel('拟合值')
plt.ylabel('残差')
plt.title('残差 vs. 拟合值')
plt.show()
# 结果近似满足方差齐性

#3 线性关系检验, 这里以人口自然增长率为例
sm.graphics.plot_ccpr(main.model_ 义务, '人口自然增长率/%')
plt.title('人口自然增长率对义务教育在校生的 CCPR 图')
plt.show()
# 经检验, 点云均绕直线分布, 线性假设合理。

# 筛选显著自变量
print(main.model_ 义务.summary())

# 其余模型预测均同理。
```

附录 E 多元回归法代码

```
# 导入必要库

import pandas as pd
import statsmodels.api as sm # 回归分析和统计建模库
import numpy as np
pd.set_option('display.max_columns', None) # 显示所有列
```

```

pd.set_option('display.max_rows', None)      # 显示所有行

from statsmodels.stats.outliers_influence import
↳ variance_inflation_factor

df = pd.read_excel(r'数据集\第一题整合数据.xlsx', sheet_name='1', engine=
↳ e='openpyxl')

# 自变量与因变量准备

# 自变量矩阵 X
features = [
    '出生率/%', '死亡率/%', '人口自然增长率/%', '城镇化率/%',
    '年末常驻总人口/万人', '义务教育学校数', '高中教育学校数', '高等教育'
    ↳ '学校数'
]
X = df[features]

# 添加常数项（截距）
X = sm.add_constant(X)

# 因变量
y_义务 = df['义务教育在校生/万人']
y_高中 = df['高中教育在校生/万人']
y_高等 = df['高等教育在校生/万人']

# 使用最小二乘法（OLS）对三个阶段的在校生人数分别建立回归模型并估计其参数

# 义务教育模型
model_义务 = sm.OLS(y_义务, X).fit()

# 高中教育模型
model_高中 = sm.OLS(y_高中, X).fit()

# 高等教育模型
model_高等 = sm.OLS(y_高等, X).fit()

# 进行预测
# 先进行未来三年自变量的线性预测。
# 提取年份
years = np.arange(len(df)) # 如果你的年份是按行排列的，可以用索引代替

# 自变量列表
features = [
    '出生率/%', '死亡率/%', '人口自然增长率/%', '城镇化率/%',
    '年末常驻总人口/万人', '义务教育学校数', '高中教育学校数', '高等教育'
    ↳ '学校数'
]

```

```

'''
# 论文建模用
print(model_ 义务.params) # 输出义务教育模型的回归系数
print(model_ 高中.params) # 输出高中教育模型的回归系数
print(model_ 高等.params) # 输出高等教育模型的回归系数
'''

# 储存未来三年预测结果
future_data = {}

# 对每个变量做线性拟合并外推三年
for feature in features:
    y = df[feature].values
    X = sm.add_constant(years)
    model = sm.OLS(y, X).fit()

    # 预测未来三年
    future_years = np.array([len(df), len(df)+1, len(df)+2])
    X_future = sm.add_constant(future_years)
    y_pred = model.predict(X_future)

    future_data[feature] = y_pred

# 构造未来三年的 DataFrame
df_future = pd.DataFrame(future_data)
df_future.index = [f'Year_{i}' for i in range(1, 4)]
'''

# 论文建模用
print(" 未来三年预测的自变量: ")
print(df_future)
'''

# 预测目标变量
future_X = sm.add_constant(df_future[features])

# 义务教育在校生人数预测
y_pred_ 义务 = model_ 义务.predict(future_X)

# 高中教育在校生人数预测
y_pred_ 高中 = model_ 高中.predict(future_X)

# 高等教育在校生人数预测
y_pred_ 高等 = model_ 高等.predict(future_X)

# 合并预测结果
future_predictions = pd.DataFrame({
    '义务教育在校生/万人': y_pred_ 义务,
    '高中教育在校生/万人': y_pred_ 高中,
    '高等教育在校生/万人': y_pred_ 高等
})

```

```

})

# 设置索引为 Year_1, Year_2, Year_3
future_predictions.index = ['Year_1', 'Year_2', 'Year_3']
print(" 未来三年预测的在校生人数: ")
print(future_predictions)

```

附录 F 高等教育岭回归法代码

```

import pandas as pd
import numpy as np

from sklearn.linear_model import RidgeCV
from sklearn.preprocessing import StandardScaler

df = pd.read_excel(r'数据集\第二题整合数据.xlsx')

# 选择自变量
X = df[['总户数/万户', '户均人口/人/户', '年末常驻总人口/万人',
        ↪ '出生率/%', '死亡率/%', '人口自然增长率/%', '城镇化率/%']]

# 选择因变量
y = df['高等教育在校生/万人']

# 标准化自变量
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
'''
# 检验标准化是否成功

# 计算每个特征的均值和标准差

means = pd.DataFrame(X_scaled, columns=X.columns).mean()
std_devs = pd.DataFrame(X_scaled, columns=X.columns).std()
print(" 均值: \n", means)
print(" 标准差: \n", std_devs)

# 经检验, 均值接近 0, 标准差接近 1, 标准化成功。

```

```

'''
# 构建岭回归模型并交叉验证

# 定义  的取值范围
alphas = np.logspace(-3, 3, 100)

# 构建岭回归模型并进行交叉验证
ridge_cv = RidgeCV(alphas=alphas, store_cv_values=True)
ridge_cv.fit(X_scaled, y) # 将数据拟合到模型

# 输出最佳  值
print(f" 最佳 alpha 值: {ridge_cv.alpha_}")

# 模型评估

# 回归系数
coefficients = ridge_cv.coef_
print(" 回归系数:", coefficients)

# 模型评分 ( $R^2$ )
r2 = ridge_cv.score(X_scaled, y)
print(f" 模型  $R^2$  分数: {r2}")

```

附录 G 高中教育岭回归法代码

```

import pandas as pd
import numpy as np

from sklearn.linear_model import Ridge
from sklearn.model_selection import GridSearchCV
from sklearn.preprocessing import StandardScaler

df = pd.read_excel(r'数据集\第二题整合数据.xlsx')

# 选择自变量
X = df[['总户数/万户', '户均人口/人/户', '年末常驻总人口/万人',
        ↪ '出生率/%', '死亡率/%', '人口自然增长率/%', '城镇化率/%']]

# 选择因变量
y = df['高中教育在校生/万人']

# 标准化自变量
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

```



```

'''
# 检验标准化是否成功

# 计算每个特征的均值和标准差

means = pd.DataFrame(X_scaled, columns=X.columns).mean()
std_devs = pd.DataFrame(X_scaled, columns=X.columns).std()
print(" 均值: \n", means)
print(" 标准差: \n", std_devs)

# 经检验, 均值接近 0, 标准差接近 1, 标准化成功。
'''

# 构建岭回归模型并交叉验证

# 定义 alpha 范围
param_grid = {'alpha': np.logspace(-3, 3, 100)}

# 构建岭回归模型并网格搜索交叉验证
ridge = Ridge()
grid_search = GridSearchCV(ridge, param_grid, cv=5, scoring='r2')
grid_search.fit(X_scaled, y)

# 输出最佳 alpha 和模型
print(f" 最佳 alpha 值: {grid_search.best_params_['alpha']}")

best_model = grid_search.best_estimator_

# 模型评估
coefficients = best_model.coef_
print(" 回归系数:", coefficients)

r2 = best_model.score(X_scaled, y)
print(f" 模型 R2 分数: {r2}")

```

附录 H 义务教育岭回归法代码

```

import pandas as pd
import numpy as np

from sklearn.linear_model import RidgeCV
from sklearn.preprocessing import StandardScaler

df = pd.read_excel(r'数据集\第二题整合数据.xlsx')

# 选择自变量

```

```

X = df[['总户数/万户', '户均人口/人/户', '年末常驻总人口/万人',
      ↪ '出生率/%', '死亡率/%', '人口自然增长率/%', '城镇化率/%']]

# 选择因变量
y = df['义务教育在校生/万人']

# 标准化自变量
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
'''
# 检验标准化是否成功

# 计算每个特征的均值和标准差

means = pd.DataFrame(X_scaled, columns=X.columns).mean()
std_devs = pd.DataFrame(X_scaled, columns=X.columns).std()
print(" 均值: \n", means)
print(" 标准差: \n", std_devs)

# 经检验, 均值接近 0, 标准差接近 1, 标准化成功。
'''
# 构建岭回归模型并交叉验证

# 定义 的取值范围
alphas = np.logspace(-3, 3, 100)

# 构建岭回归模型并进行交叉验证
ridge_cv = RidgeCV(alphas=alphas, store_cv_values=True)
ridge_cv.fit(X_scaled, y)

# 输出最佳 值
print(f" 最佳 alpha 值: {ridge_cv.alpha_}")

# 模型评估

# 回归系数
coefficients = ridge_cv.coef_
print(" 回归系数:", coefficients)

# 模型评分 (R²)
r2 = ridge_cv.score(X_scaled, y)
print(f" 模型 R² 分数: {r2}")

```

附录 I 皮尔逊相关性分析代码

```

import pandas as pd
import seaborn as sns

```

```

import matplotlib.pyplot as plt

plt.rcParams['font.sans-serif'] = ['Microsoft YaHei']

# 读取数据
df = pd.read_excel('数据集\第二题整合数据.xlsx')

# 筛选人口变量与在校生成数
corr_data = df[['总户数/万户', '户均人口/人/户', '年末常驻总人口/万人', '
    ↳ 出生率/%', '死亡率/%', '人口自然增长率/%',
    ↳ '城镇化率/%',
        '义务教育在校生/万人', '高中教育在校生/万人',
        ↳ '高等教育在校生/万人']]

# 计算相关系数矩阵
corr_matrix = corr_data.corr()

# 可视化
plt.figure(figsize=(12, 10))
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm')

# 设置横坐标文字为水平显示并增加间距
plt.xticks(rotation=45, ha='right', fontsize=10)

# 手动调整边距，避免文字被截断
plt.subplots_adjust(left=0.1, right=0.9, top=0.9, bottom=0.2)

plt.title("人口变量与在校生成数的相关性热力图")
plt.show()

```

附录 J 平稳性检验（ADF 检测）代码

```

# 导入必要库
import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.tsa.stattools import adfuller
import os
print(os.getcwd())

plt.rcParams['font.sans-serif'] = ['Microsoft YaHei']

# 读取 Excel 数据
df = pd.read_excel(r'数据集\在校生成数历史数据.xlsx',
    ↳ sheet_name='17-10', engine='xlrd')

```

```

# 定义 ADF 函数
def adf_test(series, label):
    result = adfuller(series)
    print(f"\n 【{label}】 ADF 检验统计量: {result[0]}")
    print(f"{label}的 p 值: {result[1]}")
    if result[1] < 0.05:
        print(f"→ {label} 是平稳的")
    else:
        print(f"→ {label} 是非平稳的")

# 执行 ADF 检验
adf_test(df['义务教育在校生'], '义务教育')
adf_test(df['高中教育在校生'], '高中教育')
adf_test(df['高等教育在校生'], '高等教育')

#最终结果为义务教育和高等教育为非平稳,
→ 故对义务教育和高等教育在校生进行一阶差分。
df['义务教育差分'] = df['义务教育在校生'].diff()
adf_test(df['义务教育差分'].dropna(), '义务教育一阶差分')

df['高等教育差分'] = df['高等教育在校生'].diff()
adf_test(df['高等教育差分'].dropna(), '高等教育一阶差分')

# 一阶差分后高等教育仍然非平稳, 故不适合用时间序列方法做本题。

```

附录 K 时序分析预测代码

```

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import statsmodels.api as sm # 用于时间序列建模及统计分析
import scipy.stats as st # 用于 Shapiro-Wilk 正态性检验

from statsmodels.stats.diagnostic import acorr_ljungbox # Ljung-Box
→ 检验
from statsmodels.tsa.holtwinters import ExponentialSmoothing
from sklearn.metrics import mean_squared_error,
→ mean_absolute_error#评估模型性能

# 设置中文字体
plt.rcParams['font.family'] = ['Microsoft YaHei']

# 原始数据
data = {
    'year': list(range(2015, 2024)),

```

```

    'exp': [597.52, 643.98, 658.67, 686.65, 677.74, 720.48, 709.2,
    ↪ 748.41, 835.33]
}
df = pd.DataFrame(data) # 创建数据框

# 设置时间索引
df['date'] = pd.to_datetime(df['year'], format='%Y')
df.set_index('date', inplace=True)

# 取单列作为序列
series = df['exp']

# 构建模型
model = ExponentialSmoothing(
    series,
    trend='add',
    damped_trend=True,
    seasonal=None
)

# 拟合模型（自动估计平滑参数）
fit = model.fit(optimized=True)

'''
# 建模用

# 获取趋势（b_t）和水平（_t）估计值
# 水平估计值
level_estimates = fit.level

# 趋势估计值
trend_estimates = fit.trend

# 打印水平和趋势估计
print(" 水平估计 (_t):")
print(level_estimates)

print(" 趋势估计 (b_t):")
print(trend_estimates)

result_df = pd.DataFrame({
    'year': df.index.year,
    '水平估计 (_t)': level_estimates,
    '趋势估计 (b_t)': trend_estimates
})

print(result_df)
'''

```

```

'''
# 建模用

# 检验模型拟合程度是否达标

# 1. 拟合值与残差
fitted_vals = fit.fittedvalues
residuals = series - fitted_vals

# 2. 计算 RMSE、mae、mape
rmse = np.sqrt(mean_squared_error(series, fitted_vals))
mae = mean_absolute_error(series, fitted_vals)
mape = np.mean(np.abs((series - fitted_vals) / series)) * 100
print(f"RMSE: {rmse:.2f} 亿元")
print(f"MAE: {mae:.2f} 亿元")
print(f"MAPE: {mape:.2f}%")
# 该指标很低，表示拟合和预测结果非常优秀。

# 3.Q-Q 图
sm.qqplot(residuals, line='s')
plt.title('残差 Q-Q 图')
plt.show()
# 数据点大致落在参考直线附近，正态性成立。

# 4.Ljung-Box 检验
max_lag = min(10, len(residuals) - 1)
lb_df = acorr_ljungbox(residuals, lags=[max_lag], return_df=True)
lb_stat = float(lb_df['lb_stat'].iloc[0])
lb_pvalue = float(lb_df['lb_pvalue'].iloc[0])

print(f"Ljung-Box 检验 (lag={max_lag})")
print(f"  检验统计量: {lb_stat:.4f}")
print(f"  p-value:      {lb_pvalue:.4f}")

# 判断
if lb_pvalue > 0.05:
    print("→ 残差不显著自相关（可视为白噪声）")
else:
    print("→ 残差存在自相关，需要进一步建模或调整")

# 结果为不显著自相关，符合要求。

# 5. 残差图与分布图
plt.figure(figsize=(12, 5))
plt.subplot(1, 2, 1)
plt.plot(residuals.index.year, residuals, marker='o')
plt.axhline(0, linestyle='--', color='red')
plt.title('残差时间序列')

```

```

plt.xlabel('年份')
plt.ylabel('残差（亿元）')

plt.subplot(1, 2, 2)
plt.hist(residuals, bins=8, edgecolor='k')
plt.title('残差分布直方图')
plt.xlabel('残差（亿元）')
plt.ylabel('频数')
plt.tight_layout()
plt.show()
# 残差图无明显异常。

#6. Shapiro-Wilk 正态性检验
shapiro_stat, shapiro_p = st.shapiro(residuals)
print("\nShapiro-Wilk 正态性检验")
print(f"  检验统计量: {shapiro_stat:.4f}")
print(f"  p-value:      {shapiro_p:.4f}")

if shapiro_p > 0.05:
    print("→ 残差近似正态分布")
else:
    print("→ 残差偏离正态分布，可能需要变换或其他模型")
# 残差符合正态分布，满足假设。
'''
# 预测未来 3 年
forecast = fit.forecast(3)
forecast.index = pd.to_datetime([2024, 2025, 2026], format='%Y')

print("\n未来三年年度预测: ")
print(forecast)

'''# 可视化结果
plt.figure(figsize=(10, 6))
plt.plot(series.index.year, series, 'o-', label='历史经费')
plt.plot(fitted_vals.index.year, fitted_vals, 'r--', label='拟合经费')
plt.plot(forecast.index.year, forecast, 'g-o', label='预测经费')
plt.xlabel('年份')
plt.ylabel('教育经费（亿元）')
plt.title('双指数平滑：吉林省教育经费拟合与预测')
plt.legend()
plt.grid(True)
plt.show()
'''

```