




吉林大学数学建模竞赛



参赛编号： ____049____

题目： ____B____

2025

Craft

2025 年 5 月 2 日

摘 要

这里是摘要正文内容。

关键词： 关键词 1； 关键词 2； 关键词 3

一、问题重述

1.1 问题背景

吉林省地处东北地区中部，是新中国汽车工业、电影工业的摇篮。吉林省的教育事业发展势头良好，各学龄阶段教育有很多优势突出、特色鲜明的学校，全省受教育人口比例、升学比例相对较高。可通过较为科学系统的数学方法对吉林省教育事业发展进行分析，为进一步提升教育品质和科学决策水平提供参考依据。

1.2 问题要求

问题一：以近几年的吉林省教育事业发展情况，建立数学模型，分别预测未来三年内吉林省义务教育阶段、高中教育阶段、高等教育阶段的在校生人数。

问题二：结合近年来的吉林省人口数据，分析吉林省人口与本省各阶段教育之间的影响。

问题三：为提振吉林省经济发展，希望通过加大对教育事业的投入吸引人才，减少人口外流。请结合近几年的吉林省教育经费数据，对未来三年内吉林省各项教育经费做出合理预算，为提高各阶段教育水平提出合适的策略分析。

二、符号说明

符号	说明
X_1	出生率/%
X_2	死亡率/%
X_3	人口自然增长率/%
X_4	城镇化率/%
X_5	年末常驻人口数/万人
X_6	义务教育学校数
X_7	高中教育学校数
X_8	高等教育学校数
X_9	吉林省总户数/万人
X_{10}	吉林省户均人口/（人/户）
$Y^{(1)}$	义务教育在校生人数/万人
$Y^{(2)}$	高中教育在校生人数/万人
$Y^{(3)}$	高等教育在校生人数/万人
β_n	多元线性回归系数
γ	岭回归系数向量
γ_n	岭回归系数

三、问题分析

针对问题一：考虑到有准确的在校生人数历史数据 [1]（整理后如下图 3-1），可以选择建立时间序列模型，因其无需对复杂的因果关系进行深入分析，且适合短期预测。但通过实际计算我们发现义务教育和高等教育的相关数据不满足时间序列的建立条件，即时间序列不平稳，且在进行一阶差分之后仍不平稳（具体见附件代码）。这意味着时间序列模型的基本假设不成立，因此无法直接应用。为了避免这一问题，我们转而考虑多元线性回归模型预测第一题。该模型不仅能够处理多重变量之间的关系，还能够解决数据不平稳的问题，符合第一题的实际情况。并且，多元线性回归

模型具有较高的解释性，能够通过回归系数反映各个自变量对因变量的具体贡献，给出更为合理的预测结果。因此，最终我们决定使用多元线性回归模型解决第一题。




图 3-1

针对问题二：考虑到有出生率死亡率等多个已知数据 [1](整理后如下表 3-1)，我们开始仍然考虑用多元线性回归模型。可以通过同时分析多个自变量与各阶段教育的线性关系，直观揭示变量间的复杂关系。但通过实际计算我们发现自变量之间的相关度过高，在多元线性回归用普通最小二乘法估计的系数方差急剧增大即容易出现过度拟合。因此无法选用多元线性回归来解决。为了避免上述问题，我们考虑用岭回归来通过增加惩罚项压缩系数大小降低模型对数据对微小波动的敏感性，减少因共线性导致的波动。同时通过牺牲少量偏差显著降低方差提高模型的精准度。因此我们最后选择用岭回归模型来解决第二题。

我们选择总户数，户均人口，年末常驻总人口，出生率，死亡率，人口自然增长率，城镇化率为自变量。各个阶段教育分别为因变量。

先将自变量标准化即把每个自变量的均值近似变为 0，标准差近似为 1。然后构建岭回归模型并通过交叉验证来选出最佳的正则化参数，最后来计算岭回归系数。

模型评估通过计算出决定系数 R^2 来判断拟合的程度，决定系数越接近 1 则说明拟合的越好。

年份	X_1	X_2	X_3	X_4	X_5	X_9	X_{10}
2013	7.74	5.17	2.57	55.74	2668	959.7	2.78
2014	8.03	6.45	1.58	56.81	2642	960.7	2.75
2015	6.2	5.8	0.4	57.64	2613	879.6	2.97
2016	7.45	5.95	1.49	58.75	2567	907.1	2.83
2017	7.13	6.97	0.15	59.71	2526	960.5	2.63
2018	6.35	6.79	-0.44	60.85	2484	927	2.68
2019	6.39	7.55	-1.16	61.63	2448	948.7	2.58
2020	4.84	7.81	-2.97	62.64	2399	1025.4	2.34
2021	4.7	8.08	-3.38	63.36	2375	1019.5	2.33
2022	4.33	8.4	-4.07	63.73	2348	978.2	2.4
2023	3.77	9.16	-5.39	64.72	2339	995.5	2.35

表 3-1

四、问题一模型的建立与求解

4.1 数据分析与处理

由分析，我们将建立多元线性回归方程，因此各自变量间的相关性应尽可能弱且与在校生人数相关性高。故建立模型方程为：

$$Y^{(i)} = \beta_0 + \sum_{j=1}^8 \beta_j X_j$$

我们采用最小二乘法估计系数向量 β ：

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

其中 $\mathbf{X}$ 为自变量 $X_i (i = 1, \dots, 8)$ 与年份 t 的设计矩阵， $\mathbf{Y}$ 为因变量向量
由此还注意到我们还需要 2025-2027 年的 $X_1, \dots, X_8$ 。观察历年相关数据 [1]（整理如图 4-1 至 4-3）




图 4-1




图 4-2




图 4-3

可以发现各变量变化趋势呈线性，故对各变量线性拟合，可得其预测值 $\hat{X}_{i, future}$ 的时间序列线性回归方程：

$$\hat{X}_{i, future} = \alpha_0 + \alpha_1 t + \epsilon$$

其中 α_0 为常数, α_1 为年际变化率, ϵ 为随机误差。参数估计方法目标函数为:

$$\min_{\alpha_0, \alpha_1} \sum_{i=1}^8 [X_i - (\alpha_0 + \alpha_1 t_i)]^2$$

可解得:

$$\hat{\alpha}_1 = \frac{\sum (t_i - \bar{t})(X_i - \bar{X})}{\sum (t_i - \bar{t})^2}, \hat{\alpha}_0 = \bar{X} - \hat{\alpha}_1 \bar{t}$$

这样我们就能得到变量 $X_1, \dots, X_8$ 未来三年的预测值, 结果如下:

符号	值	符号	值	符号	值
X_1	3.624	X_1	3.213909	X_1	2.803818
X_2	9.224	X_2	9.577545	X_2	9.931091
X_3	-5.600182	X_3	-6.363545	X_3	-7.126909
X_4	65.931273	X_4	66.835273	X_4	67.739273
X_5	2276.327273	X_5	2240.427273	X_5	2204.527273
X_6	6859	X_6	6527	X_6	6195
X_7	481	X_7	475	X_7	470
X_8	68	X_8	69	X_8	70

Year1

Year2

Year3




图 4-4




图 4-5




图 4-6

4.2 建模求解

由上述分析我们知道:

$$\hat{Y}^{(i)} = \hat{\beta}_0 + \sum_{j=1}^8 \hat{\beta}_j \hat{X}_j$$

我们通过以下参数来判断模型拟合程度:

- 残差是否近似正态分布, 如果近似, 则意味着模型的误差是随机的, 没有系统性的模式, 且符合经典线性回归假设。我们检验残差后, 发现我们的模型满足近似正态分布的结果 (具体见代码)
- 异方差检验。我们通过绘制“残差拟合值”散点图, 发现我们的残差在拟合值的整个范围内随机分布, 没有明显规律性或趋势, 表明我们的模型没有明显的异方差问题, 满足方差齐性的假设。(具体见代码)

借助 statsmodels.api 库的 OLS 函数, 线性回归系数的计算结果如下:

符号	值	符号	值	符号	值
β_0	2707.2656	β_0	987.3537	β_0	69.1046
β_1	-997.6949	β_1	-301.3441	β_1	208.6819
β_2	1000.0800	β_2	301.4557	β_2	-209.2665
β_3	1001.7301	β_3	301.0550	β_3	-211.1939
β_4	-22.0836	β_4	-11.0388	β_4	0.3707
β_5	-0.3513	β_5	-0.1484	β_5	-0.0291
β_6	0.0055	β_6	-0.0024	β_6	-0.0043
β_7	-1.0721	β_7	-0.1035	β_7	0.2464
β_8	2.8807	β_8	2.9065	β_8	-0.4878

$Y^{(1)}$ 的方程参数

$Y^{(2)}$ 的方程参数

$Y^{(3)}$ 的方程参数

最后, 我们得出对未来三年在校人数的预测如下:

符号	值	符号	值	符号	值
$Y^{(1)}$	167.6	$Y^{(1)}$	165.02	$Y^{(1)}$	162.43
$Y^{(2)}$	54.85	$Y^{(2)}$	54.64	$Y^{(2)}$	54.43
$Y^{(3)}$	92.29	$Y^{(3)}$	94.94	$Y^{(3)}$	97.59




图 4-7

五、问题二模型的建立和求解

5.1 数据分析与处理

由分析，我们将建立岭回归方程，我们的目标是计算岭回归系数 γ 其各个分量的值，通过分析比较系数大小来分析比较各个人口相关的自变量对各阶段教育在校人数的影响：

$$\mathbf{y} = \mathbf{X}\boldsymbol{\gamma} + \boldsymbol{\epsilon}$$

其中 $\mathbf{y}$ 是因变量在校生人数按年份排列构成的列向量， $\mathbf{X}$ 是 7 个自变量 ($X_1, \dots, X_5, X_9, X_{10}$) 按年份排列构成的矩阵， $\boldsymbol{\gamma}$ 是岭回归系数的向量，表示每个自变量各自的权重， $\boldsymbol{\epsilon}$ 是误差项。

我们想要找到最佳 α 值，它将最小化带有标准化项的损失函数，即：

$$\min_{\boldsymbol{\gamma}} \left[\sum_{i=1}^3 (y_i - \mathbf{X}_i \boldsymbol{\gamma})^2 + \alpha \sum_{j=1}^7 \gamma_j^2 \right]$$

其中 α 是标准化参数，用于控制模型的复杂度， γ_j 表示对应自变量 X_j 的回归系数 ($j=1,2,\dots,5,9,10$)。

在对自变量标准化之后，我们仍然采用最小二乘法计算回归系数：

$$\hat{\boldsymbol{\gamma}} = (\mathbf{X}^T \mathbf{X} + \alpha \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

其中：

- $\mathbf{X}^T$ 是自变量矩阵 $\mathbf{X}$ 的转置。
- $\mathbf{I}$ 是单位矩阵，确保正则化存在，避免过度拟合。

5.2 建模求解

由上述分析我们知道：

$$\hat{\boldsymbol{\gamma}} = (\mathbf{X}^T \mathbf{X} + \alpha \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

我们主要通过参数 R^2 来判断模型拟合程度， R^2 的公式如下：

$$R^2 = 1 - \frac{\sum(Y_i - \hat{Y}_i)^2}{\sum(Y_i - \bar{Y})^2}$$

我们将通过 R^2 接近 1 的程度来评估模型优度， R^2 越接近 1 模型优度越高。

计算过程中我们发现高中教育阶段的拟合不顺利，原因是高中教育阶段数据波动太小，线性关系较弱，于是我们采用网格搜索算法辅助求解，最终拟合优度 R^2 接近 0.8。虽然我们的模型对高中教育阶段的拟合较差，但是对于义务教育和高等教育阶段的拟合比较理想。

线性回归系数向量 γ 、 R^2 以及最佳 α 值的计算结果如下表 5-1：

符号	值	符号	值	符号	值
α	0.4642	α	0.0081	α	2.47708
γ_1	0.8652	γ_1	-3.3490	γ_1	-1.8920
γ_2	-4.5962	γ_2	-1.5243	γ_2	1.5775
γ_3	2.6845	γ_3	-1.2448	γ_3	-1.8088
γ_4	-1.0113	γ_4	-13.9089	γ_4	1.1220
γ_5	0.7258	γ_5	2.6127	γ_5	-1.1494
γ_9	1.3624	γ_9	-9.8182	γ_9	0.1425
γ_{10}	-0.7611	γ_{10}	-21.3902	γ_{10}	-0.7407
R^2	0.9321	R^2	0.7812	R^2	0.9610

义务教育

高中教育

高等教育

表 5-1

虽然表格数据明确但并不能直观反应出各人口变量和在校生人数的关系的权重。

我们采用了皮尔逊相关性分析法，并绘制了人口变量与在校生人数的相关性热力图如下图 5-1：




图 5-1

参考文献

- [1] 来源: 2024 吉林统计年鉴. chinese. 2025. URL: <http://tjj.jl.gov.cn/tjsj/tjnj/2024/ml/indexc.htm> (visited on 05/01/2025).